

Informe Proyecto de Ciclo

SISTEMA BASADOS EN CONOCIMIENTOS

Docente: | Ing. Janneth Alexandra Chicaiza Espinoza Elaborado por: | Luis Alfredo Febre Paucar Luis Alfredo Jaramillo Uday (11) Fecha: | 04/08/2020

Contenido

| 1. | | Int | roducción | 2 |
|----|----|------|--|----|
| 2. | | De | sarrollo | 2 |
| | a. | (| Obtención de datos | 2 |
| | b. | (| Obtención de datos RDF | 3 |
| | | I. | Tareas de Limpieza | 3 |
| | | II. | Selección de patrones URI y definición de licencia | 4 |
| | | III. | Lógica de transformación de datos con JENA | 5 |
| | | IV. | Resultados de la transformación | 8 |
| | | V. | Elección de repositorio de almacenamiento | 8 |
| 3. | | Ар | licación | 8 |
| | a. | 1 | Trabajos relacionados | 8 |
| | b. | ŀ | Herramientas utilizadas | О |
| | c. | (| Consultas SPARQL | 11 |
| | d. | L | Lógica de la APP | 4 |
| 4. | | Coi | nclusiones | 17 |

1. Introducción

RDF es un lenguaje para representar información sobre recursos en la World Wide Web. Está particularmente indicado para representar metadatos sobre recursos web, tales como el título, autor y otras licencias de información sobre documentos web, así como la disponibilidad para algunos recursos compartidos. RDF es muy útil en situaciones en las que la información necesita ser procesada por aplicaciones que intercambian información legible por máquina, más que por humanos. RDF puede utilizarse en diferentes áreas como en la recuperación de recursos para los buscadores, robots y agentes inteligentes, catalogación para describir el contenido y las relaciones de contenido disponibles en un sitio web o en una colección de documentos, para describir los derechos de propiedad intelectual o las políticas de privacidad de un sitio web, etc.

En el presente trabajo, se busca utilizar algunas de sus áreas de aplicación, sobre datos de publicaciones científicas con respecto a COVID-19, empezando por un proceso de obtención de datos y su posterior limpieza, seguido a esto su generación y almacenamiento de datos RDF, culminando con el desarrollo de una aplicación, que nos permita observar los resultados obtenidos durante todo el trabajo.

2. Desarrollo

A. OBTENCIÓN DE DATOS

Para el presente trabajo se optó por trabajar una fuente de datos, la cual se la detalla a continuación:





Formato data recolectada:

PDF



Para la búsqueda de resultado, se utilizo las palabras claves "COVID-19" y "SARS-COV-2", además de seleccionar la categoría de "Review articles", que nos permitirá capturar datos más precisos, en cuanto al tema se refiere. Cabe destacar también que los datos que utilizaremos cuentan con una fecha de corte del 16/06/2020, es decir, los datos se encuentran actualizados hasta dicha fecha.

B. OBTENCIÓN DE DATOS RDF

I. Tareas de Limpieza

Para esta actividad se tomaron en cuenta varias opciones como, por ejemplo, revisión ortográfica, eliminación de datos duplicados, eliminación de caracteres especiales y por último el cambio de nombres de países y ciudades en un idioma unificado.

Luego basándonos en el modelo ontológico definido, se procedió con la creación del modelo de base datos, el cual nos permitirá el almacenamiento de toda la data recolectada, para su posterior consumo, a la hora de generar nuestro archivo RDF.

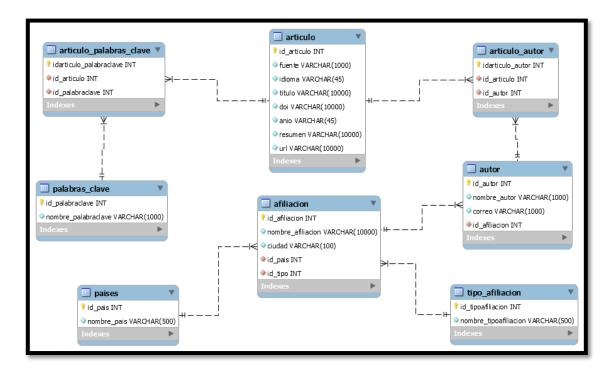


Ilustración 1. Modelo de base de datos.

Posterior a esto se generó en el archivo Exel, los insert SQL de toda la data recolectada.

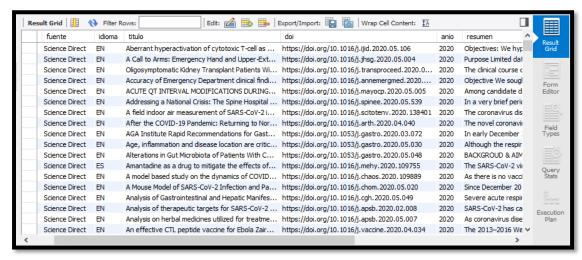


Ilustración 2. Data almacenada en la base de datos.

II. Selección de patrones URI y definición de licencia

Para este apartado se buscó la definición más optima posible, para las diferentes URIs, obteniendo como resultado lo siguiente:

URI base:

http://utpl.edu.ec/lod/publishingCOVID/

URI desarrollada para conceptos o propiedades:

http://utpl.edu.ec/lod/publishingCOVID/ontology/

Para las diferentes instancias de los diversos recursos con los que se cuenta, se utilizó el siguiente esquema:

| Clase | URI |
|----------------------|--|
| Autor | /Author/Author + id_autor |
| Articulo | / BibliographicResource/Article + id_article |
| Organización | /Organization/Organization + id_afiliacion |
| País | /Country/nombre_pais |
| Ciudad | /City/nombre_ciudad |
| Tipo de organización | /nombre_tipo_afiliacion |

III. Lógica de transformación de datos con JENA

Para el proceso de transformación de datos, se aplico una arquitectura de tres capas:

- 1. Capa de presentación.
- 2. Capa de negocio.
- 3. Capa de datos.

A continuación, se explica a breves rasgos lo desarrollado con NetBeans, como nuestro IDE y JENA como la librería que nos ayudara en la creación del archivo RDF.

Conexión con la base de datos MySQL

Ilustración 3. Conexión base de datos.

• Consulta multi tabla, la cual nos permitirá obtener todos la data recolectada, con sus respectivas relaciones.

```
public class dataAdministracion {
   Conectar con = new Conectar();
   public ResultSet ConsultarPublicacion() throws SQLException, ClassNotFoundException {
        PreparedStatement pst = (PreparedStatement) con.getConectar().prepareStatement("SELECT art.id_articulo , art.ti
        ResultSet rs = pst.executeQuery();
        return rs;
    }
}
```

Ilustración 4. Consulta multi tabla.

 Creación tripleta RDF, ya con la data recolectada en base a la consulta realizada a la base de datos, instanciamos los objetos con las clases establecidas anteriormente, para crear nuestro objeto de tipo publicación, recorriéndolo por medio de un array, con el fin de poder generar nuestro archivo RDF.

```
public static void main(String[] args) throws FileNotFoundException, SQLException, ClassNotFoundException {
    BLAdministración objetoBL = new BLAdministración();

    ArrayList<Publicacion> lstpublicacion = new ArrayList();

    lstpublicacion = objetoBL.consultarPublicacion();
```

Ilustración 5. Recuperación de consulta por medio de un ArrayList.

• Definición de prefijos, definimos los prefijos necesarios para la creación de las diferentes propiedades.

```
String dataPrefix = "http://utpl.edu.ec/lod/publishingCOVID/";
model.setNsPrefix("data", dataPrefix);
String foaf = "http://xmlns.com/foaf/0.1/";
model.setNsPrefix("foaf", foaf);
//Fijar Prefijo para otros vocabularios como DBPedia que no están d
String dbo = "http://dbpedia.org/ontology/";
model.setNsPrefix("dbo", dbo);
Model dboModel = ModelFactory.createDefaultModel();
//Fijar Prefijo para otros vocabularios como DBPedia que no están d
String dbr = "http://dbpedia.org/ontology/";
model.setNsPrefix("dbr", dbr);
String fabio = "http://purl.org/spar/fabio/";
model.setNsPrefix("fabio", fabio);
Model fabioModel = ModelFactory.createDefaultModel();
String dct = "http://purl.org/dc/terms/";
model.setNsPrefix("dcterms", dct);
Model dctermsModel = ModelFactory.createDefaultModel();
```

Ilustración 6. Definición de prefijos.

 Por último, creamos nuestros Resources, que nos permitirán la creación de nuestro archivo RDF.

Ilustración 7. Creación de los Resource.

 Resultados, una finalizada la codificación de nuestro programa procedemos con la ejecución del mismo dándonos como resultado nuestro archivo RDF.

Ilustración 8. Archivo RDF generado.

IV. Resultados de la transformación

El número de instancias generadas a partir de los datos recolectados son los siguientes:

| Clase | INSTANCIA |
|----------------------|-----------|
| Autor | 2693 |
| Articulo | 381 |
| Organización | 1059 |
| País | 48 |
| Ciudad | 112 |
| Tipo de organización | 3 |

V. Elección de repositorio de almacenamiento



Para el almacenamiento nos inclinamos por GraphDB ya que nos permite almacenar, organizar y gestionar contenido en forma de datos inteligentes semánticamente enriquecidos. Además, incluye integración de datos e interconexión, cumplimiento estándares W3C, modelo de datos expresivo, rico y flexible, espacio único de información interconectado formado por datos estructurados y documentos de texto, razonamiento, compatibilidad con datos abiertos vinculados y procedencia de datos.

Algunas de las características destacables, están su versión gratuita, su implementación es diversos sistemas operativos, ofrece formación en diferentes modos, además de asistencia en línea.

3. Aplicación

A. TRABAJOS RELACIONADOS

 Extracción de Datos Enlazados desde Información No Estructurada Aplicando Técnicas de PLN y Ontologías. En este trabajo se presenta un método para la extracción automática de datos enlazados a partir de información textual no estructurada en idioma español e inglés. El método está basado en la extracción de una conceptualización del texto en forma de mapa conceptual, la cual es posteriormente transformada en un modelo de dados RDF. En la extracción de la conceptualización se aplican diversas técnicas de PNL y se brinda la posibilidad de utilizar una ontología, para incrementar las capacidades de extracción de información del texto. Se realizaron pruebas usando tres colecciones de textos en español e inglés para evaluar la propuesta, con resultados prometedores en la extracción de conceptos y relaciones entre ellos, y mostrando también los beneficios del uso de ontologías como recurso de conocimiento externo.

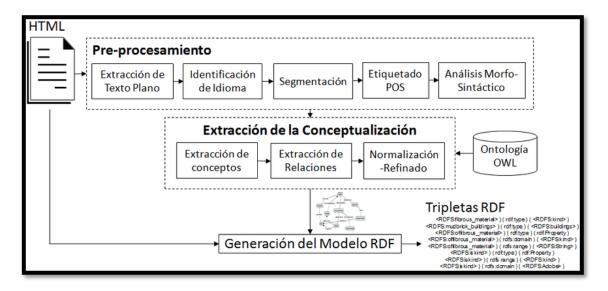


Ilustración 9. Fases y componentes del método propuesto para la extracción de DE.

LODifier: Generando datos vinculados de texto no estructurado

La extracción automatizada de información del texto y su transformación en una descripción formal es un objetivo importante en la investigación de la Web Semántica y lingüística computacional. La información extraída se puede utilizar para una variedad de tareas, como la generación de ontologías, la respuesta a preguntas y recuperación de información. LODifier es un enfoque que combina un análisis semántico profundo con reconocimiento de entidad con nombre, desambiguación de sentido de palabra y semántica controlada. Vocabularios web para extraer entidades nombradas y relaciones entre ellas del texto y convertirlos en una representación RDF que esté vinculada a DBpedia y WordNet.

Presentamos la arquitectura de nuestra herramienta y discutimos el diseño decisiones tomadas Una evaluación de la herramienta en una tarea de detección de enlaces de historia proporciona evidencia clara de su potencial práctico.

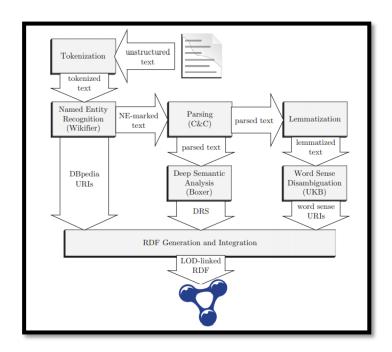


Ilustración 10. Arquitectura LODifier.

B. HERRAMIENTAS UTILIZADAS

HTML

HTML es un lenguaje de marcado que nos permite indicar la estructura de nuestro documento mediante etiquetas. Este lenguaje nos ofrece una gran adaptabilidad, una estructuración lógica y es fácil de interpre-tar tanto por humanos como por máquinas, ya que siguen un esquema de árbol donde existe un elemento raíz y donde el resto de etiquetas se insertan de manera lógica y estructurada. Además, se trata de un fichero de texto, y solo se necesita un editor como el bloc de notas para generar un documento HTML.

CSS

El CSS (hojas de estilo en cascada) es un lenguaje que define la apariencia de un documento escrito en un lenguaje de marcado. Así, a los elementos de la página web creados con HTML se les dará la apariencia que se desee utilizando CSS: colores, espacios entre elementos, tipos de letra, etc., separando de esta forma la estructura de la presentación.

BOOTSTRAP4

Bootstrap, es un framework originalmente creado por Twitter, que permite crear interfaces web con CSS y JavaScript, cuya

particularidad es la de adaptar la interfaz del sitio web al tamaño del dispositivo en que se visualice. Es decir, el sitio web se adapta automáticamente al tamaño de una PC, una Tablet u otro dispositivo. Esta técnica de diseño y desarrollo se conoce como "responsive design" o diseño adaptativo.

MORRIS.JS

Morris.js nos ofrece por medio de java script la oportunidad de crear de gráficos estadísticos intuitivos de forma fácil y adaptativo a nuestras necesidades.

• Librería Flask-GraphQL

Librería de Python que nos permitirá crear las consultas SPARQL.

C. CONSULTAS SPARQL

En la definición del proyecto se estableció algunas preguntas las cuales buscamos contestar por medio de las siguientes consultas, sobre nuestros datos RDF.

✓ Consulta Nro. 1

Cuantos títulos hacen referencia a la palabra COVID-19.

```
PREFIX rdf: <http://www.w3.org/1999/02/22-rdf-syntax-ns#>
PREFIX dcterms: <http://purl.org/dc/terms/>
select DISTINCT ?uriArticulo ?titulo WHERE{
     VALUES ?palabra {"COVID-19"} .
     ?uriArticulo rdf:type [];
     dcterms:title ?titulo .
     FILTER CONTAINS(?titulo, ?palabra)
} ORDER BY ?titulo
```

✓ Resultado

| Filter query results Showing results from 1 to 133 of 133. Query took 0.3s, moments a | | | |
|---|--|---|--|
| | uriArticulo | ♦ titulo ♦ | |
| 1 | data:ontology/BibliographicResource/Article-2 | "A Call to Arms: Emergency Hand and Upper-Extremity Operations During the CO VID-19 Pandemic" | |
| 2 | data:ontology/BibliographicResource/Article-13 | "A model based study on the dynamics of COVID-19: Prediction and control" | |
| 3 | data:ontology/BibliographicResource/Article-24 | "A novel IDEA: The impact of serial interval on a modified-Incidence Decay and Exponential Adjustment (m-IDEA) model for projections of daily COVID-19 cases" | |
| 4 | data:ontology/BibliographicResource/Article-31 | "A search for medications to treat COVID-19 via in silico molecular docking models of the SARS-CoV-2 spike glycoprotein and 3CL protease" | |
| 5 | data:ontology/BibliographicResource/Article-5 | "ACUTE QT INTERVAL MODIFICATIONS DURING HYDROXYCHLOROQUINE-AZITHR OMYCIN TREATMENT IN THE CONTEXT OF COVID-19 INFECTION" | |

✓ Consulta Nro. 2

Que actores cuentan con correo electrónico.

Resultado

| Fil | Filter query results Showing results from 1 to 207 of 207. Query took 1s, moments ago | | |
|-----|---|--------------------|---------------------------|
| | autor \$ | nombreAutor \$ | correo \$ |
| 1 | data:ontology/Author/author-1 | "Chang Kyung Kang" | "hangrae2@snu.ac.kr" |
| 2 | data:ontology/Author/author-1006 | "Xiangning Fu " | "fuxn2006@aliyun.com" |
| 3 | data:ontology/Author/author-1032 | "Fan Cheng" | "646064793@qq.com" |
| 4 | data:ontology/Author/author-1033 | "Xiangpan Li" | "rm001227@whu.edu.cn" |
| 5 | data:ontology/Author/author-1046 | "E. Maseda" | "emilio.maseda@gmail.com" |

✓ Consulta Nro. 3

Cuáles son los nombres de los Autores, cuya afiliación pertenece a un mismo País.

✓ Resultado

| Fi | lter query results | Showing results from 1 to 39 of 39. Query took 0.3s, moments ago. |
|----|--------------------|--|
| | nombrePais ÷ | Autores |
| 1 | "Argentina" | "E. Gogniat,M. Campos,G. Tusman" |
| 2 | "Australia" | "Andrew M. Lew,Michael J. Bourke,Nicholas G. Burgess,Neal Shahidi,Sunil Gupta,N icole Gilroy,Lidia Morawska,Santosh K. Tadakamadla,Cristobal G. dos Remedios" |
| 3 | "Austria" | "Walter Reinisch 'Benedikt Heidinger'Helmut Prosch'Sadegh Niazi" |
| 4 | "Belgium" | "Jean-Francois Rahier" |
| 5 | "Brasil" | "E. Cunha-Neto,D.S. Rosa,Fábio A.M. Cássaro,Luiz F. Pires,Flavio Steinwurz ,Bruno Siciliano,Guilherme Dantas,Cleyton M. da Silva,Graciela Arbilla" |

✓ Consulta Nro. 4

Cuales son los autores por cada publicación.

✓ Resultado

| Filter query results Showing results from 1 to 187 of 187. Query to | | | Showing results from 1 to 187 of 187. Query took 1.8s, moments ago. |
|---|---|--|---|
| | | nombreArticulo \$ | Autores \$ |
| 1 | "A Call to Arms: Emergency Hand and Upper-Extremity Operations During the CO VID-19 Pandemic" | | "Myoung-don Oh,Shawn Diamond MD,Jonathan B. Lundy,Gregory Rafijah,Amber Leis,Erin L. Weber,Shadi Lalezari,Benjamin L. Gray,Ines C. Lin,Ranjan Gupta " |
| 2 | "A Mouse Model of SAR | S-CoV-2 Infection and Pathogenesis" | "Yue-Lei Shen,Long Zhou,Xiao Yang,You-Chun Wang,Quan Liu,Rui Xiong,Yan Guo, Yong-Qiang Deng,Wei-Jin Huang,Guan Yang,Yan-Xiao Wang,Xing-Yao Huang,Su- Su Liu,Na-Na Zhang,Xiao-Feng Li,Shi-Hui Sun,Qi Chen,Hong-Jing Gu" |
| 3 | "A Sequence Homology ts for Immune Respons | and Bioinformatic Approach Can Predict Candidate Targe ses to SARS-CoV-2" | "John Sidney,Yun Zhang,Richard H. Scheuermann,Bjoern Peters,Alessandro Sett e" |
| 4 | "A field indoor air measurement of SARS-CoV-2 in the patient rooms of the larges $t\ hospital\ in\ Iran"$ | | "Masud Yunesian,Fatemeh Momeniha,Adel Mokamel,Mohammad Sadegh Hassan vand,Talat MokhtariAzad,Mansour Shamsipour,Nazanin Zahra Shafiei Jandaghi,Kh osro Sadeghniiat,Ramin Nabizadeh,Sasan Faridi,Sadegh Niazi,Kaveh Sadeghi,Kaz em Naddafi,Jila Yavarian" |
| 5 | "A model based study of control" | on the dynamics of COVID-19: Prediction and | "Anupam Khatua,Sayani Adak,T.K. Kar,Manotosh Mandal,Soovoojeet Jana,Swapan Kumar Nandi" |

✓ Consulta Nro. 5

Cuantas organizaciones existen, clasificadas por su tipo.

✓ Resultado

| Fil | Filter query results Showing results from 1 to 3 of 3. Query took 12s, moments ago. | | |
|-----|---|--------------------|--|
| | nombreTipoAfiliacion | cantidad ≑ | |
| 1 | "Institute" | *89***xsddinteger | |
| 2 | "Laboratory" | "471" "xad.integer | |
| 3 | "University" | *907* "xsdinteger | |

D. LÓGICA DE LA APP

El aplicativo Web cuenta con una interfaz sencilla que nos indicara en un breve resumen el resultado obtenido a nuestras consultas SPARQL, detallándolas por medio de tablas y gráficos intuitivos para una mayor comprensión, el aplicativo Web se detalla a continuación.

En la página de inicio se puede visualizar cuatro opciones, que van hacer las que nos permitan navegar por el aplicativo:



Ilustración 11. *Interfaz principal del aplicativo*.

Detalle de las opciones:

Primera opción, nos permitirá observar por medio de una tabla, a todos los autores que cuenten con correo electrónico.

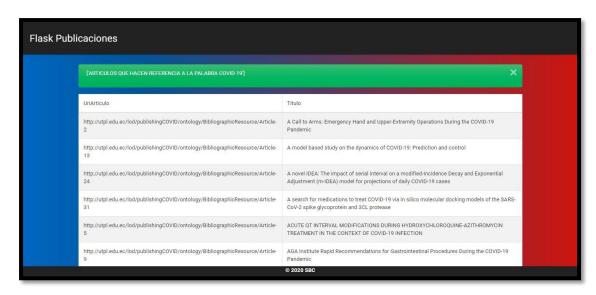


Ilustración 12. Interfaz opción 1.

Segunda opción, nos permitirá conocer todas las publicaciones en donde en su titulo se encuentre presenta la palabra "COVID-19".

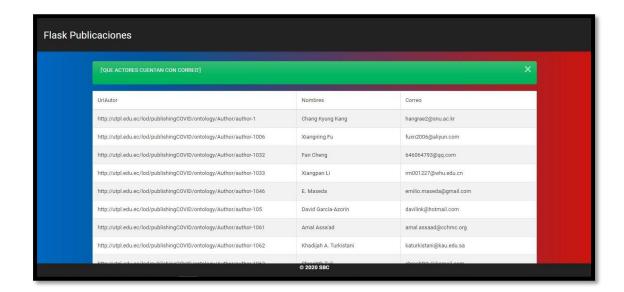


Ilustración 13. Interfaz segunda opción.

Tercera opción, nos permitirá conocer medio un grafico de Dona, el número de tipos de organizaciones que se encuentran presentes en las publicaciones.



Ilustración 14. Interfaz tercera opción.

Cuarta opción, nos permitirá observar por medio de grafico de barras el número de autores por País.



Ilustración 15. Interfaz cuarta opción.

4. Conclusiones

Podemos concluir que la generación de datos RDF, es muy importante ya que, al ser un modelo de metadatos basado en XML, nos ofrece ser un estándar flexible para la estructura de la información digital.

El trabajo realizado durante todas las etapas del presente proyecto, empezando por la recolección de datos, creación del modelo ontológico, su posterior almacenamiento en una base de datos, el consumo y generación del archivo RDF con data recolectada y su inclusión en un aplicativo Web, es proceso arduo, pero que nos ayuda a comprender que en la actualidad la utilización de datos en cada una de los sistemas informáticos es altamente necesaria, ya que permite acercar a la comunidad a comprender un poco más a cerca de los diferentes temas expuestos en estos sistemas informáticos. abriendo una brecha en el mundo del conocimiento y adquisición de información.